Guia-ponte: aprendizado de máquina e vespas sociais

O que cada algoritmo faz com os nossos dados, por que ele ajuda e o que ele não prova

Documento de apoio ao artigo *Lost signatures* (não submeter)

25 de outubro de 2026

Sumário

1 Para que serve este guia **1**

2 Biologia mínima para quem vem do ML **2**

3 Aprendizado de máquina mínimo para quem vem da biologia **4**

4 Cada algoritmo: o que faz, o que responde e por que ajuda **5**

4.1 Jaccard, PCoA, PERMANOVA e PERMDISP (descrever) . . . 5
4.2 Classificador nulo (referência) . . . 5
4.3 Regressão logística multinomial com penalização L_2 (baseline interpretável) . . . 6
4.4 k vizinhos mais próximos com Jaccard (a ponte mais direta) . . . 6
4.5 Árvore de decisão (o tijolo das florestas) . . . 6
4.6 Random Forest (modelo flexível principal) . . . 6
4.7 Random Forest ponderado e *Balanced* Random Forest (corrigir o viés) . . . 7
4.8 Gradient boosting raso (checagem de robustez) . . . 7
4.9 AUC por pares + bootstrap pareado (o teste da homogeneização) . . . 7
4.10 Probabilidades fora da amostra e o triângulo (descrever o grau) . . . 8
4.11 Importância por permutação fora da amostra + teste de Altmann (explicar) . . . 8
4.12 Dependência parcial (a "curva de tolerância" vista pelo modelo) . . . 8
4.13 SHAP (contribuição de cada espécie a cada previsão) . . . 8
4.14 IndVal.g (a visão clássica das indicadoras) . . . 8
4.15 Validação cruzada com blocos espaciais . . . 9
4.16 Análises de sensibilidade (a conclusão sobrevive?) . . . 9

5 Lista ampliada de algoritmos possíveis **9**

6 Como ler cada figura do artigo **10**

7 O que o aprendizado de máquina NÃO prova aqui **10**

8 Glossário de equivalências **11**

9 Como rodar **11**

1 Para que serve este guia

O artigo junta duas formações. Quem programa e conhece aprendizado de máquina (ML) e matemática sabe como os modelos funcionam, mas não sabe por que uma vespa da tribo Epiponini precisa de mata ripária. Os biólogos do grupo sabem o oposto. Este guia faz a tradução nos dois

sentidos e explica, algoritmo por algoritmo, **que pergunta biológica cada análise responde** e **se ela ajuda a descrever, a prever ou a explicar**.

A ideia central do artigo cabe numa frase:

> *Se a lista de vespas de um ponto permite adivinhar de que paisagem ele veio, a paisagem tem identidade; se duas paisagens são sistematicamente confundidas, as identidades delas se sobrepõem — e é exatamente isso que a homogeneização biótica prevê para uma área úmida degradada.*

O classificador, portanto, não é o objetivo: é um **instrumento de medida** da identidade ecológica. Como todo instrumento, ele precisa ser calibrado (validação, controle do acaso, correção do desbalanceamento), e é por isso que o artigo tem tantas análises de controle.

Pergunta biológica	Análise	Tipo	Onde
A composição muda entre paisagens?	Jaccard + PCoA, PERMANOVA, PERMDISP	descrever	Fig. 1, `run/01`
A lista de espécies identifica a paisagem?	7 classificadores + validação cruzada + permutação	prever	Fig. 2, `run/02`
O Pantanal ficou parecido com o Cerrado?	AUC por pares + bootstrap pareado	testar	Fig. 3, `run/03`
Quais espécies fazem (ou apagam) a fronteira?	importância, dependência parcial, SHAP, IndVal	explicar	Figs. 4–5, `run/04`
A conclusão é robusta?	blocos espaciais, n igual, sem espécies, campanhas	validar	Tab. S2, `run/05`

2 Biologia mínima para quem vem do ML

Vespas sociais (Vespidae: Polistinae)

Vespas que vivem em colônias com rainha(s) e operárias. No Brasil há três tribos nos nossos dados: *Epiponini* (*Agelaia*, *Polybia*, *Apoica*, *Brachygastra*, *Parachartergus*), que fundam colônias por **enxameagem** (um grupo de operárias sai com rainhas e constrói um ninho grande, às vezes com milhares de indivíduos); e *Polistini* (*Polistes*) e *Mischocyttarini* (*Mischocyttarus*), de **fundação independente** (uma ou poucas fêmeas iniciam um ninho pequeno). Ninhos grandes e duradouros exigem vegetação estruturada, água e muitas presas; por isso as Epiponini são sensíveis à estrutura do habitat.

Por que vespas são bons "sensores"

O ninho depende de substrato vegetal, de fibras e de água; a colônia depende de presas (outros insetos). Mudanças na vegetação e no microclima (insolação, dessecação) afetam diretamente onde colônias conseguem existir.

Armadilha atrativa suspensa

Garrafa com suco de fruta (goiaba, laranja, maracujá) pendurada na vegetação por quatro dias. É um *sensor com viés*: só detecta espécies atraídas por isca açucarada e que forrageiam perto do ponto. Malaise e puçá (rede) detectam outras espécies, mas o esforço foi diferente entre áreas, então ficaram fora do modelo.

Registro independente (deduplicação)

Uma armadilha perto de um ninho pode pegar 50 operárias da *mesma colônia*. Contar indivíduos mediria "distância até o ninho mais próximo", não "a espécie ocorre aqui". Por isso contamos cada combinação espécie × ponto × data uma vez. Em ML: é como remover duplicatas quase idênticas que inflariam o peso de um exemplo. Resultado: 358 indivíduos viram 99 registros em 46 pontos.

Zero não é ausência
Um zero na matriz significa "não detectada naquele ponto e data", não "a espécie não existe ali". A detecção é imperfeita; espécies raras geram muitos zeros. Por isso modelos baseados em árvores (que não supõem distribuição) e medidas de presença/ausência (Jaccard) são escolhas naturais.

Assembleia / comunidade
O conjunto de espécies de um grupo (aqui, vespas sociais) num local. É o nosso vetor de *features*: cada coluna da matriz é uma espécie.

Diversidade alfa, beta e gama
Alfa = riqueza num ponto (número de espécies). Beta = quão diferentes os pontos são entre si. Gama = total da região. A homogeneização biótica é uma **queda da diversidade beta** entre lugares que deveriam ser diferentes.

Espécie indicadora, especialista e generalista
Especialista: só vive num tipo de ambiente (ex.: *Agelaia pallipes* só apareceu na várzea). Generalista: tolera muitos ambientes (ex.: *Agelaia bequaerti*, em 91% dos pontos do Pantanal e 82% dos do Cerrado). Indicadora: espécie cuja presença informa o tipo de ambiente — em ML, uma *feature* muito informativa e com explicação biológica plausível.

Homogeneização biótica
Perturbação humana elimina especialistas e favorece generalistas; comunidades de lugares diferentes ficam parecidas. **Tradução para ML:** as classes passam a se sobrepor no espaço de *features*; o erro de Bayes entre elas aumenta; o AUC do par cai em direção a 0,5.

As três paisagens
Planície de inundação (Parque Estadual das Várzeas do Rio Ivinhema): várzea preservada, alagada sazonalmente, com mata ripária; bacia do rio Paraná. *Pantanal* (APA Baía Negra, Ladário): área úmida do Pantanal com uso humano (unidade de uso sustentável); bacia do rio Paraguai. *Cerrado* (Parque Nacional da Serra da Bodoquena): planalto seco, savana e florestas estacionais; bacia do rio Paraguai. A hipótese é que o Pantanal "deveria" se parecer com a várzea (ambas alagáveis), mas, degradado, passou a se parecer com o Cerrado.

Pulso de inundação
O ciclo anual de cheia e seca que estrutura as áreas úmidas: cria e destrói habitats, renova nutrientes, define quais plantas (e, portanto, quais vespas) podem viver ali.

Estação seca e chuvosa
Em Mato Grosso do Sul a seca vai, grosso modo, de maio a setembro/outubro. A atividade das vespas muda com a estação. **Importante:** as áreas foram coletadas em campanhas diferentes (Cerrado em set/2025, quase todo o Pantanal em nov/2025, a várzea em jan–jun/2024). A estação e o ano são, portanto, variáveis de confusão.

Bacia hidrográfica e decaimento com a distância
Comunidades próximas tendem a ser mais parecidas só por estarem perto (*distance decay*). O Pantanal e o Cerrado estudados estão a 224 km um do outro e na mesma bacia; a várzea está a 592 km do Pantanal, noutra bacia. Isso é uma explicação alternativa forte para a semelhança Pantanal–Cerrado.

Pseudo-replicação
Cada paisagem é *uma única área*. Os 11 pontos do Pantanal não são 11 Pantanais; são 11 amostras do mesmo lugar (espalhadas por menos de 1 km). **Tradução para ML:** a classe "Pantanal" é idêntica ao grupo "Baía Negra"; o modelo aprende a reconhecer *lugares*, e não há como testar a generalização para outro Pantanal. Por isso o artigo fala em "estudo de caso" e "compatível com", não em "prova".

3 Aprendizado de máquina mínimo para quem vem da biologia

Classificação supervisionada
Damos ao algoritmo exemplos com a resposta certa (a lista de espécies de um ponto e a paisagem de onde ele veio) e ele aprende uma regra que, dada uma lista nova, devolve a paisagem mais provável e a probabilidade de cada uma.

Treino e teste
O modelo aprende com parte dos pontos e é avaliado em pontos que *não viu*. Avaliar nos mesmos pontos do treino é como o aluno corrigir a própria prova: a nota sai alta e não significa nada.

Validação cruzada (CV) estratificada repetida
Dividimos os 46 pontos em 5 partes com a mesma proporção de paisagens; treinamos em 4 e testamos na 5ª, girando até cada ponto ter sido testado uma vez. Repetimos isso 50 vezes com sorteios diferentes. Com tão poucos pontos, um único sorteio pode dar sorte ou azar; a repetição mostra a faixa de resultados plausíveis.

Out-of-bag (OOB)
No Random Forest cada árvore não vê cerca de 1/3 dos pontos; testar cada ponto só nas árvores que não o viram dá uma estimativa parecida com a CV. Foi o que o rascunho usou (acurácia OOB 73.9%, que reproduzimos exatamente em Python).

Sobreajuste e vazamento
Sobreajuste = decorar ruído em vez do padrão (o modelo vai bem no treino e mal em dados novos). Vazamento = informação do teste "vazar" para o treino — por exemplo, dois pontos vizinhos quase idênticos, um no treino e outro no teste. Os dois inflam a acurácia. A CV com blocos espaciais (Seção 4.15) controla o vazamento por vizinhança.

Matriz de confusão
Tabela observado × previsto. A diagonal são os acertos; fora dela, os erros, e *para onde* eles vão. No rascunho, ela era o resultado principal; agora é apoio.

Acurácia e acurácia balanceada
Acurácia = fração de acertos. Com classes de tamanhos diferentes ela engana: um modelo que nunca diz "Pantanal" ainda acerta 35 de 46 pontos (76%). A **acurácia balanceada** é a média do acerto em cada paisagem; esse modelo teria 67% (100%, 100%, 0%), e o acaso dá cerca de 33%.

Kappa de Cohen
Acerto descontando o que se acertaria por acaso. 0 = acaso; 1 = perfeito.

Log-loss
Penaliza o modelo por ter *certeza* e errar. Avalia as probabilidades, não só o rótulo. Menor é melhor.

AUC (área sob a curva ROC)
Para duas paisagens A e B: a probabilidade de o modelo dar nota maior a um ponto de A do que a um ponto de B. 0,5 = moeda (indistinguíveis); 1 = separação perfeita. É a métrica central do teste de homogeneização.

Probabilidade vs. rótulo
O modelo devolve, por exemplo, Pantanal 0,48, Cerrado 0,49, várzea 0,03. O rótulo seria "Cerrado", mas a informação biológica está nas probabilidades: esse ponto é meio Pantanal, meio Cerrado e nada várzea.

Desbalanceamento de classes
O Pantanal tem 11 pontos; a várzea, 18. Modelos comuns tendem a "empurrar" casos duvidosos

para as classes maiores. Isso, sozinho, *imitaria* a homogeneização (Pantanal sendo chamado de Cerrado). Por isso usamos pesos de classe e o *Balanced Random Forest*.

Hiperparâmetro
"Botão" de configuração do algoritmo que não é aprendido dos dados (número de árvores, número k de vizinhos). Fixamos valores-padrão de antemão, para não "procurar" o botão que dá o melhor resultado (isso inflaria a acurácia), e testamos outros valores na análise de robustez.

Teste de permutação
Embaralhamos os rótulos das paisagens e refazemos *toda* a validação centenas de vezes. Se a acurácia real supera quase todas as embaralhadas, o padrão não é acaso. É exatamente o raciocínio da PERMANOVA que vocês já usam.

Bootstrap
Reamostrar os pontos com reposição milhares de vezes e recalcular a estatística; a dispersão dos resultados dá o intervalo de confiança.

4 Cada algoritmo: o que faz, o que responde e por que ajuda

Para cada análise: *em uma frase*; *o que faz com os nossos dados*; *que pergunta responde*; *por que ajuda*; *cuidados*; *onde está*.

4.1 Jaccard, PCoA, PERMANOVA e PERMDISP (descrever)

Em uma frase
Medem o quanto as listas de espécies dos pontos se parecem e testam se as paisagens ocupam regiões diferentes desse "espaço de semelhança".

O que faz
Jaccard entre dois pontos = fração das espécies que *não* é compartilhada (0 = mesma lista; 1 = nada em comum). A PCoA desenha os pontos num plano em que a distância aproxima a dissimilaridade. A PERMANOVA compara a variação entre paisagens com a variação dentro delas (pseudo-F, R^2) e obtém o p por permutação. A PERMDISP testa se uma paisagem é apenas mais "espalhada" que outra.

Responde
As composições diferem? (Sim: $R^2 = 0.354$.) E par a par? A várzea difere das duas; Pantanal × Cerrado não ($p_{\text{Holm}} = 0.085$).

Por que ajuda
É a linguagem que os revisores de ecologia esperam e conecta o artigo ao manuscrito irmão (reproduzimos o mesmo $F = 11.77$).

Cuidados
Diz *se* há diferença, não *quanto* um grupo virou o outro, nem em que direção — é aí que entra o ML.

Onde
`src/community.py`, `run/01_community_description.py`; Fig. 1.

4.2 Classificador nulo (referência)

Em uma frase
"Chuta" sempre a paisagem mais comum no treino.

Por que ajuda

Define o piso. Sem ele, "74% de acerto" não quer dizer nada: com estas proporções, chutar sempre "várzea" acerta 39%. Acurácia balanceada do nulo: 0.29 [0.29, 0.29].

4.3 Regressão logística multinomial com penalização L_2 (baseline interpretável)

Em uma frase

Dá a cada espécie um peso por paisagem; somando os pesos das espécies presentes, obtém a probabilidade de cada paisagem.

Responde

Um modelo *linear* (sem interações entre espécies) já basta?

Por que ajuda

Se ela empata com os modelos complexos, a mensagem biológica é simples: cada espécie contribui isoladamente. Aqui ela chegou a 0.67 [0.60, 0.74], perto das florestas — o sinal é forte e simples.

Cuidados

Espécies raras ganham pesos instáveis; a penalização L_2 "encolhe" os pesos para controlar isso.

4.4 k vizinhos mais próximos com Jaccard (a ponte mais direta)

Em uma frase

Um ponto recebe a paisagem dos 5 pontos com a fauna mais parecida.

Responde

O que a semelhança de composição, sozinha, implica?

Por que ajuda

É a versão preditiva da análise de similaridade dos ecólogos. Aqui ele mandou 94.5% dos pontos do Pantanal para o Cerrado: pela composição pura, os pontos do Pantanal "moram" no meio dos pontos do Cerrado.

Cuidados

Muito sensível ao desbalanceamento (vizinhos tendem a ser da classe maior).

4.5 Árvore de decisão (o tijolo das florestas)

Em uma frase

Uma sequência de perguntas sim/não sobre espécies: "tem *A. pallipes*? → várzea; senão, tem *P. ruficeps*? → Pantanal; senão → Cerrado".

Por que ajuda

Captura combinações (interações) e ignora zeros irrelevantes. Sozinha é instável: muda muito com poucos pontos diferentes.

4.6 Random Forest (modelo flexível principal)

Em uma frase

Centenas de árvores, cada uma treinada com um sorteio dos pontos e, em cada pergunta, com um sorteio das espécies; a previsão é a votação (média das probabilidades).

Responde

A combinação de espécies identifica a paisagem, incluindo interações?

Por que ajuda

É o padrão em ecologia para dados de comunidade: lida com zeros, espécies raras e não linearidade, sem supor distribuição. O sorteio torna as árvores diferentes entre si e a média reduz o erro.

Cuidados

Sem correção, favorece as classes grandes (ver a próxima).

4.7 Random Forest ponderado e *Balanced* Random Forest (corrigir o viés)

Em uma frase

O ponderado dá mais peso aos pontos da classe pequena; o balanceado treina cada árvore com o mesmo número de pontos de cada paisagem.

Por que ajuda — e por que é essencial aqui

A hipótese H2 é justamente "o Pantanal (classe pequena) é confundido com o Cerrado". Um modelo enviesado para classes grandes produziria essa confusão mesmo sem homogeneização. O RF sem correção (o do rascunho) mandou 65.1% dos pontos do Pantanal para o Cerrado; o balanceado, 56.4%. E mais: no RF sem correção a confusão parecia de mão única (Cerrado "absorvendo" o Pantanal: só 13.2% dos pontos do Cerrado iam para o Pantanal); com classes balanceadas ela ficou mútua (35.6% do Cerrado vão para o Pantanal). A sobreposição é sinal biológico; a assimetria do rascunho era artefato do tamanho das classes.

4.8 Gradient boosting raso (checagem de robustez)

Em uma frase

Árvores pequenas em sequência, cada uma corrigindo os erros das anteriores.

Por que ajuda

Outra forma de combinar árvores. Se chega às mesmas conclusões, o resultado não é peculiaridade de um algoritmo.

Cuidados

Sobreajusta fácil com n pequeno; por isso profundidade 2 e folhas com ≥ 4 pontos.

4.9 AUC por pares + bootstrap pareado (o teste da homogeneização)

Em uma frase

Treina um classificador só Pantanal × Cerrado e outro só Pantanal × várzea e compara quão separáveis os pares são.

Responde

Diretamente a H2: $\mathrm{AUC}_{\mathrm{Pan\times Cer}} < \mathrm{AUC}_{\mathrm{Pan\times Fpl}}$?

Por que ajuda

Transforma "o modelo confundiu" numa *medida com intervalo de confiança*, que não depende do desbalanceamento de uma matriz de confusão de 3 classes. Resultado: Pantanal × várzea = 1.00 [1.00, 1.00]; Pantanal × Cerrado = 0.56 [0.32, 0.78]; diferença = 0.44 [0.22, 0.68].

Bootstrap pareado

Os dois AUCs usam os mesmos 11 pontos do Pantanal; por isso reamostramos esses pontos uma vez só para os dois. Assim a incerteza da diferença é calculada corretamente.

Onde

`run/03_homogenization_test.py`; Fig. 3 (figura principal do artigo).

4.10 Probabilidades fora da amostra e o triângulo (descrever o grau)

Em uma frase

Para cada ponto, as probabilidades das três paisagens, plotadas num triângulo (cada vértice = certeza de uma paisagem).

Por que ajuda

Mostra um *gradiente*, não sim/não. Os pontos do Pantanal ficam sobre a aresta Pantanal–Cerrado e longe do vértice da várzea: probabilidade média de Cerrado 0.47, de várzea 0.03. É a imagem da homogeneização.

4.11 Importância por permutação fora da amostra + teste de Altmann (explicar)

Em uma frase

Embaralha uma espécie entre os pontos de teste e mede quanto o modelo piora.

Responde

De quais espécies a capacidade de *generalizar* depende?

Por que ajuda

Calculada só em pontos não vistos, mede o que é útil para prever dados novos, não o que o modelo decorou. O p-valor vem de recalcular as importâncias com rótulos embaralhados (Altmann et al. 2010).

Cuidados

Espécies que ocorrem juntas dividem a importância (se uma é embaralhada, a outra "cobre"); importância negativa ou nula de uma espécie compartilhada não significa que ela não importa biologicamente, só que ela não ajuda a *separar*.

4.12 Dependência parcial (a "curva de tolerância" vista pelo modelo)

Em uma frase

Como a probabilidade de cada paisagem muda quando fixamos a frequência de uma espécie em 0, 1, 2 registros em todos os pontos.

Por que ajuda

Dá a *direção* do efeito. Lição importante para os dois artigos: a "afinidade" de *A. bequaerti* depende do peso das classes. No RF sem correção ela parece indicar Cerrado (47%); com classes balanceadas ela sobe tanto Pantanal (39%) quanto Cerrado (40%); o IndVal, que também iguala os grupos, a coloca no Pantanal. Conclusão biológica: ela marca o *conjunto* Pantanal+Cerrado.

4.13 SHAP (contribuição de cada espécie a cada previsão)

Em uma frase

Divide a previsão de cada ponto em contribuições somáveis das espécies (valores de Shapley da teoria dos jogos).

Por que ajuda

Explica pontos individuais: "neste ponto, a presença de *P. ruficeps* empurrou a probabilidade de Pantanal para cima em 0,3". Complementa a importância global.

4.14 IndVal.g (a visão clássica das indicadoras)

Em uma frase

Combina especificidade (a espécie está concentrada numa paisagem?) e fidelidade (aparece na maioria dos pontos dessa paisagem?).

Por que ajuda

É o que o manuscrito irmão usou; comparar com a importância do ML mostra onde os dois olhares concordam (especialistas da várzea) e onde divergem (generalistas compartilhados).

4.15 Validação cruzada com blocos espaciais

Em uma frase

Agrupa os pontos de cada área em 3 manchas e testa sempre uma mancha inteira que o modelo não viu.

Por que ajuda

Se pontos vizinhos inflassem a acurácia, ela despencaria aqui. Caiu um pouco (0.56 vs. 0.62), e o Pantanal continuou indistinguível do Cerrado (AUC 0.47).

Limite

Não resolve a pseudo-replicação entre áreas (só há uma área por paisagem).

4.16 Análises de sensibilidade (a conclusão sobrevive?)

Cada cenário muda uma decisão: presença/ausência, sem espécies de um ponto só, 11 pontos por paisagem, sem *A. bequaerti*, outros hiperparâmetros, checagens de campanha. O AUC Pantanal × Cerrado ficou entre 0.47 e 0.58 em todos; o Pantanal × várzea, sempre ≥ 0.98.

5 Lista ampliada de algoritmos possíveis

Além do que está implementado, estes métodos podem entrar em versões futuras ou em artigos derivados. "Agora" = faz sentido com estes dados; "futuro" = exige outro tipo de dado ou desenho.

Método	Para que serviria aqui	Situação
Nulo, logística L_2, k-NN Jaccard, RF (3 versões), boosting	Benchmark de classificação (O1)	implementado (`run/02`)
AUC por pares, probabilidades	Teste de homogeneização (O2)	implementado (`run/03`)
Importância, PDP, SHAP, IndVal.g	Espécies-chave (O3)	implementado (`run/04`)
Conditional inference forest (`cforest`, `partykit`)	Importância sem o viés do RF para variáveis com poucos valores distintos (Strobl 2007)	agora (em R)
SVM linear/RBF	Mais um classificador de margem; pouco interpretável	agora, baixo ganho
Naive Bayes de Bernoulli	Modelo de presença/ausência muito simples; bom baseline	agora, baixo ganho
Ordenação baseada em modelo (`gllvm`)	Ordenação que modela os zeros e a detecção; alternativa à PCoA	agora
`mvabund::manyglm`	Teste multivariado com GLM por espécie; diz quais espécies diferem	agora
Modelos conjuntos de distribuição (HMSC)	Explicar coocorrências por ambiente e por associação entre espécies	futuro (variáveis ambientais)
Generalized dissimilarity modelling (GDM)	Separar o efeito da distância geográfica do efeito do ambiente/perturbação	futuro (mais sítios)

Método	Para que serviria aqui	Situação
Modelos de ocupação	Corrigir detecção imperfeita (zero ≠ ausência)	futuro (visitas repetidas)
Rarefação / cobertura amostral (iNEXT)	Mostrar se a amostragem foi suficiente em cada área	agora (descritivo)
Redes neurais / deep learning	Não recomendado: $n = 46$ é pequeno demais	não
Visão computacional (CNN)	Identificar vespas por foto em monitoramento	futuro (imagens)

6 Como ler cada figura do artigo

Fig. 1 (composição)
Procure: a várzea isolada à esquerda; Pantanal (verde) dentro da nuvem do Cerrado (laranja). No painel (b), a linha "Pantanal" tem 1,00 com a várzea (nada em comum) e ≈0,57 com o Cerrado (tanto quanto dentro do próprio Pantanal).

Fig. 2 (desempenho)
Cada modelo é uma linha; pontos à direita da linha tracejada (acaso) são bons. As matrizes mostram onde ficam os erros: quase todos na célula Pantanal → Cerrado. Compare (b) e (c) para ver o efeito do balanceamento.

Fig. 3 (principal)
(a) Três pares: Pantanal–várzea e Cerrado–várzea no teto (AUC ≈1); Pantanal–Cerrado perto da linha 0,5. (b) No triângulo, os pontos verdes deitados na aresta Pantanal–Cerrado.

Fig. 4 (espécies)
(a) Quanto o modelo piora sem cada espécie (pontos cheios: $p < 0{,}05$). (b) Onde cada espécie ocorre — leia junto com (a): especialistas da várzea no topo; as compartilhadas (*A. bequaerti*, *P. ignobilis*) com importância baixa ou negativa.

Fig. 5 (dependência parcial)
Cada painel é uma espécie; as três linhas são as probabilidades das paisagens quando a espécie tem 0, 1 ou 2 registros.

Fig. S1 (SHAP)
Cada ponto é um local de coleta; à direita de zero, a espécie empurra para aquela paisagem.

Fig. S2 (robustez)
Se os pontos azuis ficam perto da linha de referência em todos os cenários, a conclusão não depende das escolhas analíticas.

7 O que o aprendizado de máquina NÃO prova aqui

Cuidado

- **Causa.** O modelo mede semelhança; não diz *por que* o Pantanal se parece com o Cerrado. Antropização, proximidade geográfica (224 km, mesma bacia) e campanha de coleta (mesmo ano, meses vizinhos) produzem o mesmo padrão.
- **Generalização.** Com uma área por paisagem, o modelo reconhece *áreas*. Não sabemos se reconheceria outra várzea ou outro trecho do Pantanal.

- **Ausências.** Zeros são não detecções de um método com viés (isca de fruta).
- **Precisão.** Com 11 pontos no Pantanal, os intervalos são largos; o artigo deve sempre mostrar os intervalos, nunca só o número.

Linguagem adequada: "compatível com homogeneização", "sugere", "indistinguível para o modelo". Evitar: "prova", "comprova", "corrobora integralmente".

Desenho que permitiria testar a causa. Várias áreas preservadas e várias antropizadas *em cada bacia*, coletadas na mesma estação; então a pergunta vira "o classificador treinado em áreas preservadas reconhece as antropizadas?" com validação *deixando uma área de fora*.

8 Glossário de equivalências

Ecologia	Aprendizado de máquina	Comentário
Ponto amostral	Exemplo, observação, linha	$n = 46$
Espécie	*Feature*, variável preditora	$p = 17$
Paisagem / fitofisionomia	Classe, rótulo, *target*	3 classes
Registro independente	Deduplicação	evita inflar colônias grandes
Matriz espécie × local	Matriz de *design* $\mathbf{X}$	esparsa (muitos zeros)
Dissimilaridade de Jaccard	Distância de Jaccard em vetores binários	usada no k-NN e na PCoA
PCoA / NMDS	Redução de dimensionalidade (MDS)	PCoA = MDS clássico
PERMANOVA	Teste de permutação de uma estatística de separação	mesmo raciocínio do teste do classificador
Espécie indicadora	*Feature* importante e interpretável	IndVal ↔ importância
Curva de resposta / tolerância	Dependência parcial (PDP)	
Homogeneização biótica	Sobreposição de classes; AUC → 0,5	o que medimos
Pseudo-replicação	Vazamento por grupo; classe = grupo	limitação principal
Autocorrelação espacial	Dependência entre exemplos	CV com blocos
Esforço amostral desigual	Mudança de distribuição (*covariate shift*)	por isso só armadilhas suspensas
Detecção imperfeita	Ruído de rótulo nas *features* (falsos zeros)	

9 Como rodar

```
python -m venv .venv
source .venv/bin/activate        # Windows: .venv\Scripts\activate
```

```
pip install -r run/requirements.txt
# coloque o arquivo de campo em data/raw/dados_vespas.csv (ver data/README.md)
WASPS_QUICK=1 python run/run_all.py     # teste rápido (~2 min)
python run/run_all.py                   # análise completa (~40 min em 2 núcleos)
git add paper data/results && git commit -m "Atualiza resultados" && git push
```

Figuras vão para `paper/figures/`, números e tabelas para `paper/generated/`; no Overleaf o texto e os números se atualizam após o push.